

Analisi del Progetto Early Warning System

Modulo #4 (Zenti) - Gruppo: Vitto, Cata, Fra, Ste, Cerro

Documento di analisi interna che riassume - parte per parte - **cosa funziona, cosa e' migliorabile**, i **numeri chiave** ottenuti e le **azioni consigliate** prima della consegna finale.

Voto interno stimato: 27-30/30 (a seconda di quanto il prof valuta la rigorosita' statistica vs i 'bei numeri').

Risultati chiave del progetto

Vincitore tecnico vs vincitore pratico

Sul confronto a 18 modelli il **LSTM-AE** (Parte 3, Fra) risulta primo per PR-AUC su 893 settimane, ma con un caveat statistico fondamentale: il **bootstrap CI 95%** e' [0.5416, 0.6600], che contiene anche Logistica (0.602), ElasticNet (0.604) e Logistica_tuned (0.598). I top 4 modelli sono **statisticamente indistinguibili**.

Implicazione: in produzione si sceglierebbe la **Logistica**, non LSTM-AE. E' 6x piu' semplice, piu' veloce, ha probabilita' meglio calibrate (Brier 0.167 vs 0.209) e prestazioni equivalenti. Va dichiarato esplicitamente nelle conclusioni.

Top 5 modelli per PR-AUC

Posizione	Modello	Famiglia	PR-AUC	Brier
1	LSTM-AE	Parte 3 - Fra	0.608	0.209
2	ElasticNet	Parte 2 - Cata	0.604	0.166
3	Logistica	Parte 2 - Cata	0.602	0.167
4	Logistica_tuned	Parte 2 - Cata	0.598	0.167
5	Ensemble (media supervised)	Parte 4 - Ste	0.578	0.161

Stacking ensemble: +12 punti PR-AUC sul meta-test

Un Logistic Regression addestrato sui punteggi normalizzati di tutti i 18 modelli batte il miglior singolo di **+0.124 PR-AUC** (0.463 vs 0.339) sulle ultime 447 settimane di valutazione. E' la dimostrazione piu' forte che combinare i modelli vale la pena.

Caveat: il delta e' calcolato su una finestra ristretta in cui il best singolo crolla a 0.339. Il guadagno e' parzialmente 'facile da battere'. Andrebbe stress-testato con rolling stacking.

Business case: il piatto forte assoluto

Il replay storico delle 3 crisi (2008, 2011, 2020) usando il modello vincente su MSCI USA mostra:

Strategia	CAGR	Volatilita	Max Drawdown	Sharpe
Buy & Hold	7.6%	15.8%	-55.2%	0.55
Risk Mgmt (q70)	5.0%	10.5%	-22.3%	0.52
Quant (q50)	3.0%	8.9%	-27.2%	0.38

Lettura risk manager: dimezziamo il drawdown massimo (-55% -> -22%) sacrificando solo 2.6 punti di CAGR e mantenendo lo Sharpe quasi invariato. Sono i numeri da mettere nella slide finale.

Replay storico per crisi

Crisi	Buy & Hold	Strategia EWS	Perdita evitata	Anticipo
2008 - Finanziaria	-39.5% / MDD -55%	-3.3% / MDD -6%	+49 punti	84 sett.
2011 - Debito euro	+13.3% / MDD -17%	-13.2% / MDD -18%	-0.6 punti	39 sett.
2020 - COVID	+7.7% / MDD -28%	-0.7% / MDD -15%	+13 punti	2 sett.

Il modello eccelle su crisi **'lente'** (2008, 84 settimane di anticipo) ed e' mediocre su **shock esogeni veloci** (COVID, solo 2 settimane). Il 2011 e' un falso allarme istruttivo: il modello vede stress sul credito che pero' non si trasforma in crisi sistemica.

Analisi parte per parte

Parte 1 - Vitto: Feature engineering

Cosa funziona

- I 9 precursori originali coprono in modo completo le sorgenti di stress: volatilità, correlazione, credito, tassi, drawdown, VIX, commercio, macro.
- L'etichetta y_{ahead} con orizzonte $H=4$ settimane e' motivata empiricamente.
- La nuova feature **absorption_ratio** e' la seconda piu' informativa (MI 0.074): contributo concreto al progetto.
- Il confronto orizzonti $H = 2 / 4 / 8$ e' metodologicamente corretto e supporta la scelta di $H=4$.

Cosa migliorerei

- **turbolenza** ha Mutual Information esattamente 0: andrebbe rimossa o ricostruita con finestra 26w invece di 52w, e includendo TUTTI gli asset (non solo equity).
- **safe_haven** ha MI = 0.007, troppo debole. Sostituire con un vero **flight-to-quality** (Treasury 10Y meno rendimento equity).
- **Dipendenza eccessiva dal VIX**: il coefficiente Logistica del VIX (1.64) e' 7x piu' grande del secondo. Manca una feature per crisi non-equity: TED spread, FRA-OIS, repo rates.
- Mancano feature di **sentiment** (Google Trends, news embeddings).

Voto interno: 8/10. Buon impianto, qualche feature da limare.

Parte 2 - Cata: Framework + Modelli supervisionati

Cosa funziona

- Walk-forward causale (START=200, STEP=12) **senza data leakage**: impeccabile.
- Sei modelli confrontati: Logistica, ElasticNet, RandomForest, GradBoosting, LightGBM, XGBoost.
- Tuning ristretto (**C in [0.3, 1, 3]**) dopo aver scoperto il problema dei valori estremi: dimostra che il processo di tuning e' stato analizzato, non applicato alla cieca.
- Platt scaling (sigmoid) invece di Isotonic per la calibrazione: PR-AUC invariata, Brier migliora.
- I numeri tornano col PDF del prof: Logistica ~0.60 PR-AUC.

Cosa migliorerei

- **Tutti i modelli ad alberi sotto la Logistica** (0.50-0.53 vs 0.60). Significa che i 9 precursori sono gia' lineari e gli alberi non aggiungono valore. Andrebbe **dichiarato esplicitamente nelle conclusioni** come risultato metodologico, non come fallimento.
- Non e' stato testato **SMOTE** (era nel PDF). Su un 32% di positivi non sposta molto ma per completezza una cella di confronto andrebbe aggiunta.
- Calibrazione applicata **solo al miglior modello**, non a tutti: per onesta' di confronto Brier dovrebbe essere calcolato su versioni tutte calibrate.
- Soglia operativa fissata a q70 arbitrariamente: andrebbe scelta ottimizzando F1 o profit sulla CV.

Voto interno: 9/10. Solido, ben costruito.

Parte 3 - Fra: Unsupervised, Temporale, Regime

Cosa funziona

- Tutti i deep dive del PDF coperti: LOF, OC-SVM, HMM 2-vs-3 stati, CUSUM, LSTM-AE.
- HMM con **conferma su validation set**: 3 stati vince sul selection ma non si conferma -> torna a 2 stati. Metodologicamente brillante.
- CUSUM applicato al **segnale composito** (media dei rilevatori): riduce il rumore.

- LSTM-AE primo per PR-AUC (0.608): da' valore concreto alla sezione.
- Fallback graceful su hmmlearn / pyod / torch: pipeline portabile.

Cosa migliorerei

- **CUSUM e' il peggior modello** (PR-AUC 0.384, sotto il random baseline 0.264). Il drift=0.4 e' arbitrario. Applicare a un singolo segnale forte (HMM o IF) invece che al composite, oppure tunare drift via grid search su Spearman vs y_ahead.
- **LSTM-AE vince ma a caro prezzo**: 6x piu' complesso di Logistica, Brier peggiore (0.21 vs 0.17), 75 ri-addestramenti su CPU. In produzione si sceglierebbe Logistica. Va detto onestamente.
- **Regime-HMM ha frac_anticipate = 0.62**: vede solo il 62% degli episodi di crisi. Le rilevazioni sono buone ma manca crisi importanti.
- Manca una **matrice di correlazione tra i soli unsupervised** per capire la ridondanza.

Voto interno: 8.5/10. Molto ricco. CUSUM da limare.

Parte 4 - Ste: Selezione, Statistica, Ensemble

Cosa funziona

- Framework dei **3 test** (predittivita', tempestivita', affidabilita') multi-criterio onesto.
- **Bootstrap CI 95%** sul vincitore: forse il punto piu' rigoroso del progetto. Rivela onestamente che la vittoria e' dentro l'incertezza statistica.
- Stacking +12 PR-AUC sul meta-test: dimostra che combinare modelli vale.
- Uncertainty signal con **top 10 allarmi incerti** concentrati nel 2008 e ottobre 2020 (seconda ondata COVID). Tutti correttamente flaggati. Storia perfetta per il report.

Cosa migliorerei

- Il **ranking a somma rank** e' troppo semplificato. Una media pesata (es. T3 affidabilita' conta doppio per un risk manager) sarebbe piu' realistica.
- Stacking valutato su 447 settimane, di cui il best singolo crolla a 0.339: il delta e' parzialmente 'facile da battere'. Servirebbe **rolling stacking** per stress-testarlo.
- Manca confronto **Brier vs PR-AUC** come tie-breaker nella selezione.
- **Ensemble semplice (media) perde** (rank 5): conclusione da estrarre esplicitamente nel report.
- **Conformal prediction** (idea PDF) per controllo falsi allarmi non implementata: sarebbe il +1.

Voto interno: 8.5/10. Bootstrap CI e stacking sono punti forti.

Parte 5 - Cerro: Explainability, Stress, Business case

Cosa funziona

- **4 archetipi di crisi** chiari: Tipo 2 (15 settimane: 2008 + COVID) = panic events, tensione_credito +2.5 sigma + VIX +2.5 sigma. Segmentazione interpretabile.
- Spiegazione locale settimana **2008-11-04**: slancio_baltic +4.95 sigma, tensione_credito +3.68 sigma, livello_vix +3.24 sigma. Storia narrativa perfetta.
- Replay storico spettacolare: **+49 punti** evitati nel 2008 con 84 settimane di anticipo.
- **Business case dual framing**: max DD dimezzato a CAGR pressoché invariato. Il piatto forte.
- t-Copula stress: continuita' col lab 3 rispettata.

Cosa migliorerei

- **Stress test t-Copula non informativo**: 99.5% degli scenari sopra soglia operativa. La soglia (q70 = 0.055) e' troppo bassa rispetto agli scenari estremi generati. Va ricalcolata sulle probabilita' predette, non sullo score grezzo.
- **2011 e' un falso allarme**: la strategia esce ma il mercato recupera. Da analizzare esplicitamente come 'fallimento istruttivo' (tensione credito reale ma confinata).

- **2020 anticipo solo 2 settimane:** il COVID e' uno shock esogeno, impossibile da prevedere con segnali macro endogeni. Va dichiarato come limite del modello.
- **SHAP non eseguito veramente** (fallback su coef). Su Logistica i coef sono gia' interpretabili, ma SHAP TreeExplainer su GradBoosting darebbe insight piu' ricchi. Per il report aggiungere `pip install shap` + 1 cella e' il +1 finale.
- **Conformal prediction** per controllo falsi allarmi non implementata.
- Business case potrebbe includere **Value-at-Risk evitato** o Expected Shortfall reduction: linguaggio da risk manager.

Voto interno: 9/10. Pezzo migliore del progetto, peccato per il t-Copula.

Cosa fare prima della consegna finale

In ordine di **rapporto valore / sforzo**, ecco gli interventi consigliati prima del commit finale:

#	Intervento	Tempo	Valore
1	Rimuovere o sistemare turbolenza (finestra 26w invece di 52w)	2 min	Alto
2	Sistemare lo stress test t-Copula (ricalibrare soglia)	5 min	Medio
3	Paragrafo onesto Logistica vs LSTM-AE nelle conclusioni	5 min	Alto
4	pip install shap + eseguire cella 120 con SHAP vero	3 min	Alto
5	Analisi esplicita del falso allarme 2011 nel report	10 min	Medio
6	Matrice correlazione tra modelli unsupervised di Fra	10 min	Basso

Cose NON da fare (ROI negativo)

- **Optuna full**: +1-2 PR-AUC, costa 30-60 minuti, rischio crash. Non vale.
- **Altri modelli**: gli alberi già sottoperformano, aggiungerne non cambia nulla.
- **Feature engineering aggiuntivo in Cata**: è compito di Vitto, non sporcare i ruoli.
- **Hyperparameter tuning estensivo dei calibrati**: marginale e fragile.

Conclusione

Voto complessivo stimato

27-30 / 30, a seconda di quanto il prof valuta la rigorosità statistica (bootstrap CI, uncertainty quantification, walk-forward causale) rispetto ai 'bei numeri di business' (MDD dimezzato, +49 punti nel 2008).

Punti di forza che giustificano il voto alto

- Pipeline completa end-to-end con un **contratto pulito** tra le 5 parti.
- Tutti i deep dive del PDF coperti, nessun gap.
- **Bootstrap CI** sul vincitore: rara onestà metodologica.
- Business case con **numeri spettacolari** (MDD -55% → -22%).
- Continuità lab 3 (HMM, t-Copula) rispettata.

Punti deboli da non nascondere ma incorniciare

- turbolenza (Vitto), CUSUM (Fra) e t-Copula stress (Cerro) non sono utili come previsto. Da inquadrare come 'esperimenti negativi documentati', non come errori.
- Il 2011 è un falso allarme: il modello non distingue 'stress reale ma contenuto' da 'crisi sistemica'. Limite onesto da dichiarare.
- LSTM-AE vince per PR-AUC ma in produzione sceglieremmo Logistica: dichiarare la scelta esplicitamente è segno di maturità, non di debolezza.
- Manca SHAP vero e conformal prediction: marginali ma sarebbero il +1.

Messaggio per il prof (suggerito)

'Abbiamo costruito una pipeline completa con 18 modelli a confronto, framework di valutazione condiviso, stress test e business case. Il vincitore tecnico (LSTM-AE) e il miglior modello pratico (Logistica) sono statisticamente equivalenti: in produzione sceglieremmo Logistica per semplicità e velocità'. La strategia

derivata dimezza il max drawdown rispetto al buy & hold, sacrificando solo 2.6 punti di CAGR e mantenendo lo Sharpe pressoché invariato. I limiti onestamente dichiarati: shock esogeni (COVID) e falsi allarmi su stress contenuto (2011 debito euro).'

Documento generato automaticamente dall'analisi dei risultati notebook.